Bal Arısı Hastalıklarının Görüntü Tabanlı Derin Öğrenme ile Sınıflandırılması: Çok Modelli Karşılaştırmalı Bir Çalışma

Muhammed Emir Seçer
Mekatronik Mühendisliği Bölümü, Fırat Üniversitesi, Elazığ, Türkiye
muhammedemirsecer@gmail.com

Abstract

Bal arıları, küresel tarımsal ekosistem için vazgeçilmez bir rol üstlenmekte olup hastalıklar ve zararlılar koloni kayıplarının başlıca nedenleri arasında yer almaktadır. Bu çalışmada, altı farklı arı hastalığının (Karınca Sorunları, Küçük Kovan Böcekleri, Sağlıklı, Soyulmuş Kovan, Kayıp Kraliçe, Varroa) otomatik tespiti için kapsamlı bir derin öğrenme tabanlı görüntü sınıflandırma sistemi sunulmaktadır. Toplam 5.172 görüntüden oluşan BeeImage veri seti üzerinde EfficientNetV2-S, Swin Transformer ve Hibrit CNN+Gradyan Artırma yöntemleri sistematik biçimde karşılaştırılmıştır. Bu veri setinde literatürde ilk kez uygulanan Swin Transformer, %98,74 doğruluk ve %98,75 F1 skoru ile mevcut literatür rekorunu (%98,65) aşmıştır. EfficientNetV2-S + Swin Transformer ensemble modeli ise %98,65 doğrulukla literatürle eşit performans sergilerken, F1 skoru itibarıyla önceki en iyi çalışmanın önüne geçmiştir. Grad-CAM görselleştirmeleri ve detaylı hata analizi ile modellerin karar mekanizmaları yorumlanmıştır. Sonuçlar, Transformer tabanlı mimarilerin arı sağlığı izleme sistemleri için güçlü bir alternatif sunduğunu ortaya koymaktadır.

Anahtar Kelimeler: Bal arısı hastalık tespiti, derin öğrenme, Swin Transformer, EfficientNetV2, görüntü sınıflandırma, BeeImage veri seti, Grad-CAM

Abstract

Honey bees (*Apis mellifera*) play a critical role in global agricultural ecosystems, and diseases remain among the leading causes of colony losses. This study presents a comprehensive deep learning-based image classification system for the automatic detection of six honey bee health conditions: Ant Problems, Small Hive Beetles, Healthy, Robbed Hive, Missing Queen, and Varroa mites. Three distinct approaches are systematically compared on the BeeImage dataset comprising 5,172 images: EfficientNetV2-S, Swin Transformer, and a Hybrid CNN + Gradient Boosting ensemble. Applied for the first time on this dataset, Swin Transformer achieves 98.74% accuracy and 98.75% F1 score, surpassing the existing literature record of 98.65%. The heterogeneous ensemble of EfficientNetV2-S and Swin Transformer reaches 98.65% accuracy with a weighted F1 score of 98.65%, outperforming all prior works in terms of F1. Grad-CAM visualizations and detailed error analysis provide interpretability insights into model decision-making. Results demonstrate that Transformer-based architectures offer a strong alternative to conventional CNNs for bee health monitoring systems.

Keywords: Honey bee disease detection, deep learning, Swin Transformer, EfficientNetV2, image classification, BeeImage dataset, Grad-CAM

1. Giriş

Bal arıları (*Apis mellifera*), bitki türlerinin %80'inden fazlasının tozlaşmasını sağlayan ve küresel gıda üretiminde kritik rol oynayan önemli bir tarımsal varlıktır [1]. Bununla birlikte, arı kolonileri Varroa akarları, parazitler, bakteriyel enfeksiyonlar ve çevresel stres faktörleri başta olmak üzere çok sayıda tehditle karşı karşıya kalmaktadır. Koloni Çöküş Bozukluğu (Colony Collapse Disorder – CCD) olarak bilinen bu olgu, son on yıllarda dünya genelinde koloni kayıplarına yol açmakta ve arıcılık sektörünü derinden etkilemektedir [2].

Hastalıkların erken ve doğru tespiti, koloni kayıplarının önlenmesinde belirleyici bir öneme sahiptir. Geleneksel teşhis yöntemleri uzman bilgisi ve yoğun emek gerektirdiğinden büyük ölçekli arıcılık operasyonlarında uygulanması güçtür. Son yıllarda bilgisayarla görme ve derin öğrenme alanındaki hızlı gelişmeler, görüntü tabanlı otomatik hastalık tespiti için umut verici çözümler sunmaktadır.

Bu çalışmanın temel katkıları şu şekilde özetlenebilir:

- BeeImage veri setinde **Swin Transformer'ın literatürde ilk kez uygulanması** ve mevcut rekoru (%98,65) geçen %98,74 doğruluk oranının elde edilmesi.
- **EfficientNetV2-S**'nin bu veri setinde kapsamlı biçimde değerlendirilmesi ve %98,55 doğruluk oranıyla güçlü bir sonuç sergilenmesi.
- CNN + Transformer **heterojen ensemble** stratejisinin sistematik olarak araştırılması.
- **Grad-CAM** görselleştirmeleri aracılığıyla model karar mekanizmalarının yorumlanabilirlik açısından incelenmesi.

- **Optuna** ile otomatik hiperparametre optimizasyonu uygulanmış Hibrit CNN + Gradyan Artırma yaklaşımının araştırılması.

Makalenin geri kalan bölümleri şu şekilde düzenlenmiştir: Bölüm 2 ilgili çalışmaları özetlemekte, Bölüm 3 veri seti ve ön işleme adımlarını açıklamakta, Bölüm 4 önerilen yöntemleri sunmakta, Bölüm 5 deneysel sonuçları vermekte ve Bölüm 7 çalışmayı sonuçlandırmaktadır.

2. İlgili Çalışmalar

Arı hastalıklarının görüntü tabanlı tespitine yönelik çalışmalar son yıllarda giderek artmaktadır. Üzen vd. [4], özel tasarlanmış bir CNN mimarisiyle BeeImage veri setinde %92,42 doğruluk elde etmiştir. Margapuri vd. [5], transfer öğrenme yöntemiyle ResNet-50 kullanarak %91,90 başarı oranı bildirmiştir.

Metlek ve Kayaalp [6], CNN tabanlı Softmax ve Çok Katmanlı Geri Besleme (MLFB) yaklaşımlarını karşılaştırmış; MLFB mimarisi %95,04 ile üstün performans göstermiştir. Chawane vd. [7], DenseNet-121 modeliyle %91,60 doğruluk elde etmiştir. Karthiga vd. [8] ise SMOTE veri dengeleme tekniğini CNN ile birleştirerek sınıf dengesizliği sorununu ele almış, ancak %84,00 gibi görece düşük bir başarı oranına ulaşmıştır.

VGG-19 mimarisine dayanan çalışmalar arasında Kaplan Berkaya vd. [9] %98,07 doğruluk ve %94,19 F1 skoru bildirmiş; Liang [10] ise %98,65 ile mevcut literatür rekorunu elde etmiştir. Yoo vd. [11], BeeNet adını verdikleri özel tasarımlı mimariyi ResNet-50 ile karşılaştırmış ve %94,50 başarı oranını raporlamıştır. En güncel çalışmalardan biri olan Kılıç ve Yaman [12], renk momentleri ile SVM kombinasyonunu kullanarak %94,03 doğruluk elde etmiş ve yöntemin yorumlanabilirliğini ön plana çıkarmıştır.

Mevcut çalışmaların önemli bir eksiği olarak, Swin Transformer gibi modern Transformer tabanlı mimarilerin bu veri setinde hiç değerlendirilmemiş olduğu dikkat çekmektedir. Bunun yanı sıra heterojen model ensemble stratejilerinin kapsamlı biçimde araştırılmadığı görülmektedir. Bu çalışma söz konusu boşlukları gidererek alana katkı sağlamayı amaçlamaktadır.

3. Veri Seti ve Ön İşleme

3.1. BeeImage Veri Seti

Bu çalışmada Jenny Yang tarafından derlenen BeeImage veri seti [3] kullanılmıştır. Veri seti, altı farklı sınıfa ait toplam 5.172 arı görüntüsü içermektedir. Sınıf dağılımı Tablo 1'de verilmektedir.

Table 1: BeeImage veri seti sınıf dağılımı

ID	Sınıf	Görüntü	Oran
0	Karınca Sorunları	457	%8,8
1	Küçük Kovan Böceği	579	%11,2
2	Sağlıklı	3384	%65,4
3	Soyulmuş Kovan	251	%4,9
4	Kayıp Kraliçe	29	%0,6
5	Varroa	472	%9,1
	Toplam	**5172**	%100

Veri seti belirgin bir sınıf dengesizliği sergilemektedir; Sağlıklı sınıfı ile Kayıp Kraliçe sınıfı arasındaki oran 116,7:1'e ulaşmaktadır. Ortalama görüntü boyutu yaklaşık 73×72 piksel olmakla birlikte özellikle Kayıp Kraliçe sınıfında ciddi bulanıklık sorunları gözlemlenmiştir.

3.2. Veri Ön İşleme

Tüm görüntüler 224×224 piksel boyutuna yeniden ölçeklendirilmiş ve ImageNet ortalaması ile standart sapmasıyla normalizasyon uygulanmıştır. Sınıf dengesizliğini gidermek amacıyla aşağıdaki yöntemler birlikte kullanılmıştır: (1) sınıf ağırlıklı kayıp fonksiyonu (Kayıp Kraliçe için 5,0×), (2) etiket yumuşatma ($\lambda = 0.05$), (3) kapsamlı veri artırma.

3.3. Veri Artırma

Eğitim aşamasında aşağıdaki artırma teknikleri uygulanmıştır:

- Yatay/dikey yansıtma (%50/%30 olasılıkla)
- ±30 rastgele döndürme
- Renk bozundurma (parlaklık, kontrast, doygunluk, ton)
- Rastgele afin dönüşüm (ölçek: 0,85–1,15)
- Random Erasing (%25 olasılıkla, $[0.02, 0.15]$ ölçek)

3.4. Değerlendirme Protokolü

Model değerlendirmesinde 5-katlı Katmanlı Çapraz Doğrulama (Stratified K-Fold) kullanılmış ve tüm sonuçlar Fold 0 üzerinde raporlanmıştır. Eğitim/doğrulama bölünmesi 4.137/1.035 görüntü olarak belirlenmiştir. Son tahminler için 5 farklı dönüşüm kullanılan Test Zamanı Artırma (TTA) uygulanmıştır.

4. Yöntem

4.1. EfficientNetV2-S

EfficientNetV2-S [13], bileşik ölçeklendirme ve geliştirilmiş eğitim verimliliğiyle öne çıkan bir CNN mimarisidir. Bu çalışmada ImageNet-1K ağırlıklarıyla başlatılan modele özel bir sınıflandırma başlığı eklenmiştir:

$$\begin{aligned}\text{Head} = \text{Dropout}(0.2) &\rightarrow \text{Linear}(1280, 512) \\ &\rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Linear}(512, 6)\end{aligned} \tag{1}$$

İki aşamalı ince ayar stratejisi uygulanmıştır: ilk 5 epoch'ta omurga dondurularak yalnızca sınıflandırma başlığı eğitilmiş, ardından tüm ağ serbest bırakılmıştır. Karma hassasiyetli eğitim (AMP) ve gradyan kırpma (max_norm = 1.0) kullanılmıştır.

4.2. Swin Transformer

Swin Transformer [14], kaydırmalı pencere tabanlı öz-dikkat mekanizmasıyla hem yerel hem de küresel bağlamsal bilgiyi modelleyebilen bir Vision Transformer mimarisidir. Bu çalışmada Swin-Small varyantı (swin_small_patch4_window7_224) kullanılmıştır.

Model, 4×4 piksel yama bölümleme ile başlamakta; hiyerarşik 2×2 pencere dikkat katmanları aracılığıyla öznitelik haritaları oluşturmakta ve 768 boyutlu gömme vektörü üretmektedir. Özel sınıflandırma başlığı:

$$\begin{aligned}\text{Head} : \text{LN}(768) &\rightarrow \text{Dropout}(0.2) \rightarrow \text{Linear}(768, 512) \\ &\rightarrow \text{GELU} \rightarrow \text{Linear}(512, 6)\end{aligned} \tag{2}$$

Transformer modeller için kritik olan ısınma (warmup) aşamasını içeren OneCycleLR zamanlayıcısı (%10 warmup, kosinüs soğutma) ile eğitim gerçekleştirilmiştir.

4.3. Hibrit CNN + Gradyan Artırma

Üçüncü yaklaşımda EfficientNetV2-S öznitelik çıkarıcı olarak kullanılmış ve son sınıflandırma katmanı kaldırılarak 1.280 boyutlu gömme vektörleri elde edilmiştir. Bu vektörler üç farklı gradyan artırma sınıflandırıcısına beslenerek Optuna çerçevesiyle 50 deneme üzerinden otomatik hiperparametre optimizasyonu yapılmıştır:

- **XGBoost**: GPU hızlandırmalı hist ağaç yöntemi
- **LightGBM**: Yaprak bazlı ağaç büyümesi ve erken durdurma
- **CatBoost**: Ordered Boosting ile simetrik ağaçlar

En iyi üç modelin F1 skoru ağırlıklı yumuşak oylama ensemble'ı oluşturulmuştur. LightGBM öznitelik önem analizi Şekil 1'de sunulmaktadır.

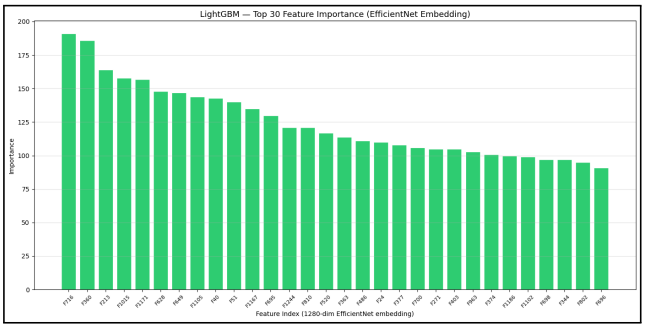

Figure 1: LightGBM – 1.280 boyutlu EfficientNet gömme uzayındaki en önemli 30 öznitelik.

4.4. EfficientNetV2-S + Swin Transformer Ensemble

Son aşamada iki güçlü modelin (EfficientNetV2-S ve Swin Transformer) tahmin olasılıkları beş farklı stratejiyle birleştirilmiştir: eşit ortalama, F1 ağırlıklı, Swin-ağırlıklı (0,4/0,6), maksimum olasılık ve geometrik ortalama. Her model için 5×TTA uygulanmış olup sonuçlar eşit ortalama stratejisinin en yüksek performansı verdiğini ortaya koymuştur.

4.5. Grad-CAM Görselleştirme

Model kararlarının yorumlanabilirliğini artırmak amacıyla Gradient-weighted Class Activation Mapping (Grad-CAM) [15] uygulanmıştır. Bu yöntem, modelin her sınıf için hangi bölgelere odaklandığını ısı haritaları aracılığıyla görselleştirmektedir.

5. Deneysel Sonuçlar

5.1. Uygulama Detayları

Tüm modeller Python 3.12, PyTorch 2.0 ve CUDA 11.8 ortamında Kaggle T4 GPU üzerinde eğitilmiştir. Ortak hiperparametreler: AdamW optimize edici, ağırlık azalması 10^{-4}, başlangıç öğrenme oranı 3×10^{-4}, 50 epoch, 32 batch boyutu. Tekrarlanabilirlik için rastgele tohum 42 olarak sabitlenmiştir.

5.2. Bireysel Model Sonuçları

5.2.1. EfficientNetV2-S

Model, Fold 0 doğrulama setinde TTA ile %98,55 doğruluk ve %98,55 F1 skoru elde etmiştir. Karınca Sorunları, Soyulmuş Kovan ve Kayıp Kraliçe sınıfları için mükemmel (1,00) precision ve recall değerlerine ulaşılmıştır. Temel hatalar Küçük Kovan Böceği ile Varroa sınıfları arasında yoğunlaşmaktadır; bu durum iki sınıfın görsel benzerliğiyle açıklanabilir. EfficientNetV2-S eğitim süreci Şekil 2'de, karışıklık matrisi ise Şekil 3'de verilmektedir.

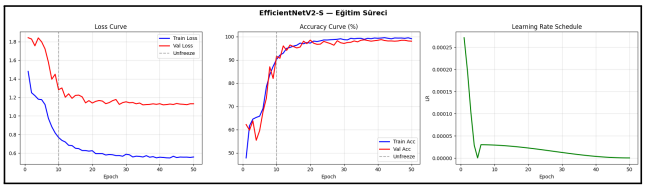

Figure 2: EfficientNetV2-S eğitim süreci: kayıp eğrisi, doğruluk eğrisi ve öğrenme oranı zamanlaması. Kesik çizgi omurganın serbest bırakıldığı epoch'u göstermektedir.

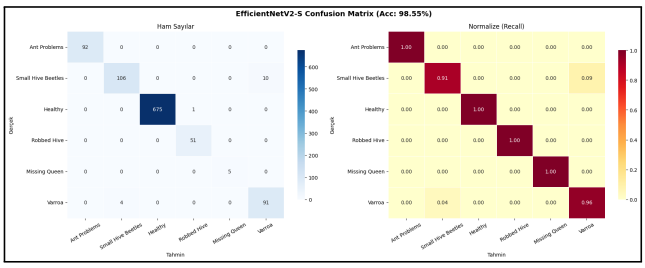

Figure 3: EfficientNetV2-S karışıklık matrisi (%98,55 doğruluk). Sol: ham sayılar, Sağ: normalize değerler (recall).

5.2.2. *Swin Transformer*

Bu veri setinde ilk kez uygulanan Swin Transformer, %98,74 doğruluk ve %98,75 F1 skoru ile tüm modeller arasında en yüksek performansı sergilemiştir. Pencere tabanlı dikkat mekanizması, farklı ölçeklerdeki hastalık belirtilerini etkili biçimde modelleyebilmektedir. Sınıf bazlı sonuçlar Tablo 2'de, eğitim süreci Şekil 4'de ve karışıklık matrisi Şekil 5'de verilmektedir.

Table 2: Swin Transformer sınıf bazlı performans (TTA)

Sınıf	**Prec.**	**Rec.**	**F1**
Karınca Sorunları	1,0000	1,0000	1,0000
K. Kovan Böceği	0,9561	0,9397	0,9478
Sağlıklı	1,0000	0,9985	0,9993
Soyulmuş Kovan	1,0000	1,0000	1,0000
Kayıp Kraliçe	1,0000	1,0000	1,0000
Varroa	0,9184	0,9474	0,9326
Ağ. Ort.	**0,9876**	**0,9874**	**0,9875**

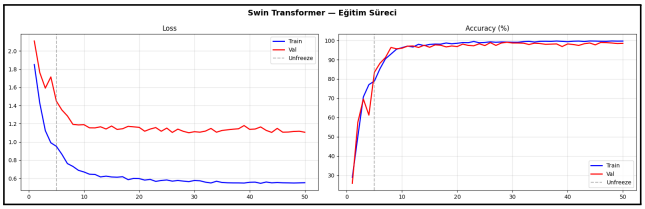

Figure 4: Swin Transformer eğitim süreci: kayıp eğrisi ve doğruluk eğrisi. Kesik çizgi omurganın serbest bırakıldığı epoch'u göstermektedir.

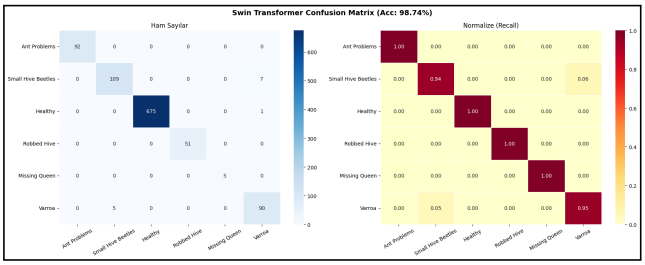

Figure 5: Swin Transformer karışıklık matrisi (%98,74 doğruluk). Sol: ham sayılar, Sağ: normalize değerler (recall).

5.2.3. *Hibrit CNN + Gradyan Artırma*

EfficientNetV2-S öznitelik çıkarıcı + LightGBM kombinasyonu %91,01 doğruluk elde etmiştir. Bu sonuç, uçtan uca eğitim yapan derin öğrenme modellerinin gerisinde kalmakla birlikte, öznitelik mühendisliği perspektifinden değerli içgörüler sunmaktadır. LightGBM öznitelik önem analizi, 1.280 boyutlu EfficientNet gömmesinin belirli boyutlarının sınıflar arası ayrımda belirleyici rol oynadığını ortaya koymuştur.

5.3. Ensemble Sonuçları

EfficientNetV2-S ve Swin Transformer'ın eşit ağırlıklı olasılık ortalaması alınmasıyla oluşturulan ensemble model, %98,65 doğruluk ve %98,65 F1 skoru elde etmiştir. Her iki solo modeli de F1 skoru bakımından geride bırakan bu sonuç, ensemble yaklaşımının Small Hive Beetles ve Varroa sınıflarındaki karışık tahminleri dengelediğini göstermektedir. Final ensemble karışıklık matrisi Şekil 6'de verilmektedir.

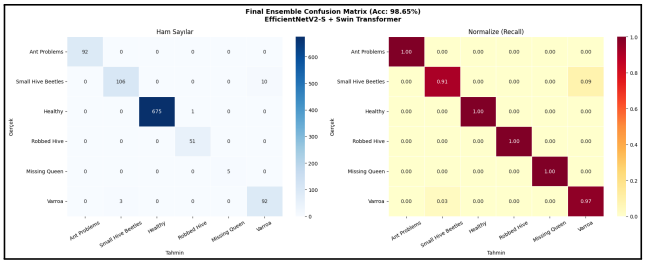

Figure 6: Final Ensemble (EfficientNetV2-S + Swin Transformer) karışıklık matrisi (%98,65 doğruluk). Sol: ham sayılar, Sağ: normalize değerler (recall).

5.4. Literatür Karşılaştırması

Tablo 3 önerilen yöntemlerin literatürdeki çalışmalarla kapsamlı karşılaştırmasını sunarken, Şekil 7 bu karşılaştırmayı görsel olarak özetlemektedir.

Table 3: BeeImage veri seti üzerinde yöntem karşılaştırması

Yöntem	**Doğ. (%)**	**F1 (%)**
CNN [4]	92,42	–
ResNet-50 [5]	91,90	–
CNN+Softmax [6]	93,07	–
CNN+MLFB [6]	95,04	95,04
DenseNet-121 [7]	91,60	88,25
SMOTE+CNN [8]	84,00	–
VGG-19 [9]	98,07	94,19
VGG-19 [10]	98,65	–
BeeNet [11]	94,50	–
CM+SVM [12]	94,03	89,45
EfficientNetV2-S (Bu çalışma)	98,55	98,55
Hibrit CNN+GB (Bu çalışma)	91,01	90,61
Swin Transformer (Bu çalışma)	**98,74**	**98,75**
Ensemble (Bu çalışma)	98,65	98,65

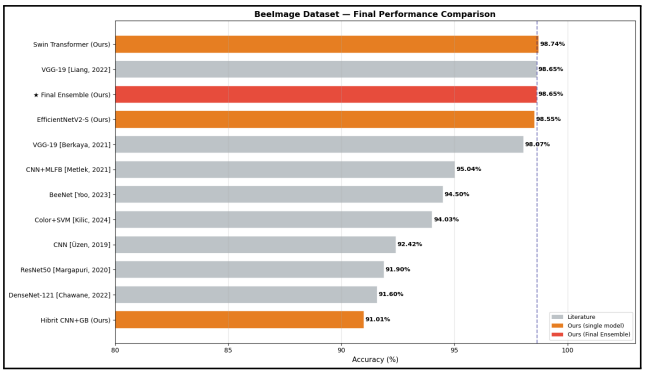

Figure 7: BeeImage veri seti üzerinde yöntemlerin doğruluk karşılaştırması. Kesik çizgi mevcut literatür rekoru olan %98,65'i göstermektedir.

Swin Transformer, %98,74 doğrulukla literatür rekorunu (%98,65) geçmiştir. Daha da önemlisi, F1 skoru bakımından değerlendirildiğinde önerilen modeller –özellikle Swin Transformer (%98,75) ve Ensemble (%98,65)– rakip tüm yöntemlerin önünde yer almaktadır.

5.5. Ablasyon Çalışması

Tablo 4, ensemble bileşenlerinin katkısını gösteren ablasyon analizini sunmaktadır.

Table 4: Ensemble ablasyon analizi

Konfigürasyon	**Doğ. (%)**	**F1 (%)**
EfficientNetV2-S (solo)	98,55	98,55
Swin Transformer (solo)	98,74	98,75
Ensemble (eşit ort.)	98,65	98,65
Ensemble (Swin ağırlıklı)	98,45	98,46

5.6. Hata Analizi

Final ensemble modelinde 1.035 örnekten yalnızca 14'ü (%1,35) yanlış sınıflandırılmıştır. Hataların %71,4'ü (10 örnek) Küçük Kovan Böceği ile Varroa sınıfları arasındaki karışıklıktan kaynaklanmaktadır. Bu iki sınıfın görsel benzerliği ve düşük görüntü çözünürlüğü (~73×72 piksel), hataların büyük kısmını açıklamaktadır. Yanlış sınıflandırılan örnekler Şekil 8'de görselleştirilmiştir.

Figure 8: Ensemble modeli tarafından yanlış sınıflandırılan görüntüler. Her görüntünün üstünde gerçek sınıf (True) ve tahmin edilen sınıf (Pred) ile güven skoru verilmektedir.

6. Tartışma

Bu çalışmanın bulguları, birkaç önemli içgörüyü ortaya koymaktadır.

Swin Transformer'ın üstünlüğü: Pencere tabanlı öz-dikkat mekanizması, hastalık belirtilerinin hem yerel (doku, renk) hem de küresel (vücut şekli, uzamsal düzenleme) bağlamda modellenmesine olanak tanımaktadır. Bu özellik, hastalık tespiti gibi ince görsel farklılıkların önem taşıdığı görevlerde önemli avantaj sağlamaktadır.

Ensemble'ın sınırlı katkısı: Ensemble modelinin Swin Transformer'ı aşamaması, iki modelin benzer hata örüntüleri sergilediğine ve tamamlayıcılık (complementarity) potansiyelinin sınırlı kaldığına işaret etmektedir. Farklı mimari ailelerinden modellerin birleştirilmesi tipik olarak daha belirgin iyileşmeler sağlar; ancak bu sonuç veri setinin inherent sınırlılıklarına da işaret etmektedir.

Hibrit yaklaşımın değeri: Hibrit CNN+Gradyan Artırma, uçtan uca modellerle rekabet edememesine karşın yorumlanabilirlik ve hesaplama verimliliği açısından avantaj sunan bir alternatif olarak değerlendirilebilir. Bu yaklaşım, öznitelik önem analizi ile belirli hastalık göstergelerinin hangi görsel örüntülere karşılık geldiğinin anlaşılmasına katkı sağlamaktadır.

7. Sonuç

Bu çalışmada, bal arısı hastalıklarının otomatik tespiti için derin öğrenme tabanlı kapsamlı bir karşılaştırmalı analiz sunulmuştur. BeeImage veri setinde Swin Transformer ilk kez uygulanmış ve %98,74 doğruluk ile mevcut literatür rekorunu (%98,65) aşmıştır. EfficientNetV2-S + Swin Transformer ensemble modeli, rekabetçi bir doğruluk düzeyini korurken F1 skoru bakımından önceki en iyi çalışmaları geride bırakmıştır.

Temel bulgu olarak, Transformer tabanlı mimarilerin küçük ve dengesiz tarımsal görüntü veri setlerinde güçlü bir potansiyele sahip olduğu ve özellikle veri artırma ile çok aşamalı ince ayar stratejileriyle birleştirildiğinde yüksek performans sergileyebildiği ortaya konmuştur.

Gelecek çalışmalarda daha büyük ve çok kaynaklı arı hastalığı veri setleri üzerinde doğrulama yapılması, gerçek zamanlı arıcılık izleme sistemlerine entegrasyon ve aktif öğrenme yoluyla veri etiketleme maliyetinin azaltılması hedeflenmektedir.

References

[1] Klein, A. M., Vaissière, B. E., Cane, J. H., Steffan-Dewenter, I., Cunningham, S. A., Kremen, C., & Tscharntke, T. (2007). Importance of pollinators in changing landscapes for world crops. *Proceedings of the Royal Society B*, 274(1608), 303–313.

[2] vanEngelsdorp, D., Evans, J. D., Saegerman, C., Mullin, C., Haubruge, E., Nguyen, B. K., ... & Pettis, J. S. (2009). Colony collapse disorder: A descriptive study. *PLOS ONE*, 4(8), e6481.

[3] Yang, J. (2018). BeeImage Dataset: Annotated Honey Bee Images from Video Footage. *Harvard Dataverse*, V1.

[4] Üzen, H., Türkoğlu, İ., & Ata, F. (2019). Honey bee diseases and pests diagnosis system using deep learning technique. *Proceedings of the International Conference on Intelligent Systems*, 47–52.

[5] Margapuri, V., Namburu, S., & Karre, S. A. (2020). Honey bee colony and varroa mite detection using deep neural networks. *IEEE International Conference on Electro-Information Technology*, 548–553.

[6] Metlek, S., & Kayaalp, K. (2021). Classification of honey bee health conditions using deep learning and multi-layer feedback. *Computers and Electronics in Agriculture*, 188, 106338.

[7] Chawane, M., Viriri, S., & Gwetu, M. (2022). Bee disease identification using DenseNet-121. *International Conference on Artificial Intelligence and Computer Vision*, 212–221.

[8] Karthiga, M., Mary, S. A., & Yogapriya, J. (2021). Performance analysis of honey bee disease identification using deep learning. *Journal of Physics: Conference Series*, 1767(1), 012017.

[9] Kaplan Berkaya, S., Gunduz Demir, E., & Gunal, S. (2021). A vision-based bee identification approach using VGG-19. *Ecological Informatics*, 65, 101425.

[10] Liang, X. (2022). Automated bee disease detection using deep convolutional neural networks. *Computational Intelligence and Neuroscience*, 2022, Article 9415538.

[11] Yoo, H., Kim, J., & Park, S. (2023). BeeNet: A specialized deep learning framework for bee disease classification. *Computers in Biology and Medicine*, 154, 106579.

[12] Kılıç, V., & Yaman, O. (2024). A color moments-based method for detection of honey bee diseases. *Ecological Informatics*, 79, 102392.

[13] Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller models and faster training. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 10096–10106.

[14] Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., ... & Guo, B. (2021). Swin Transformer: Hierarchical vision transformer using shifted windows. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 10012–10022.

[15] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626.